



Programa Institucional de Iniciação Científica e Tecnológica

Relatório Parcial de Atividades

Análise de Sentimento Econômico em Redes Sociais

Aluno: Mateus Casale Rossit Monteleone

Orientador: Alexangre Gori Maia

1. Introdução

Os dados disponíveis através da coleta em redes sociais são capazes de fornecer informações valiosas acerca das preferências e opiniões de diferentes grupos sociais; como os resultados de processos eleitorais (Maia et al., s.d.). Os eleitores brasileiros declaram as redes sociais como um meio de extração de informações importantes para o embasamento de suas decisões eleitorais (Simoes, s.d.). A literatura demonstra que o desempenho econômico influencia sistematicamente o comportamento eleitoral, fenômeno amplamente discutido nos modelos de *economic voting* (Hibbs, 1977; Muth, 1961). Tanto os formuladores de políticas quanto os eleitores preocupam-se consideravelmente com as condições correntes e futuras do cenário econômico. Nessa lógica, eleitores utilizam informações sobre inflação, desemprego e crescimento como heurísticas para avaliar incumbentes e formular expectativas, essas sendo a base para tomada de decisão.

Tradicionalmente, a análise dessas dinâmicas fundamenta-se em indicadores objetivos — os chamados *hard data* — como Produto Interno Bruto, taxa de desemprego e índices de preços. Entretanto, desde a incorporação das expectativas nos modelos macroeconômicos (Lucas, 1972; Muth, 1961), tornou-se evidente que variáveis subjetivas exercem papel fundamental na dinâmica econômica. Nesse contexto, adquirem relevância os chamados *soft data*, que capturam percepções, hipóteses e sentimentos agregados de diversos agentes, como índices de confiança do consumidor e pesquisas de opinião. Estudos recentes indicam que tais medidas podem atuar como *leading indicators*, contribuindo para exercícios de *forecasting* e *nowcasting* macroeconômico. O discurso disposto nas redes sociais não possui uma estrutura formal pré-definida, nem é organizado de maneira única; a extensa disponibilidade de dados textuais não estruturados (*unstructured data*) resultou no desenvolvimento de modelos capazes de transformar linguagem em variáveis analíticas, utilizando técnicas como *Natural Language Processing* (NLP), métodos supervisionados de *machine learning* e abordagens de análise de sentimento baseadas em léxicos ou em modelos preditivos treinados em grandes corpora textuais.

A análise de sentimento (*sentiment analysis*) insere-se no campo mais amplo de *Natural Language Processing* e tem como objetivo classificar automaticamente opiniões, subjetividade e estados afetivos expressos em dados textuais. A literatura seminal da área (Pang & Lee, 2008) define sentimento como a orientação avaliativa associada a determinado conteúdo — usualmente categorizada em polaridade positiva, negativa ou neutra — podendo também incorporar dimensões como intensidade, valência ou categorias emocionais específicas. Em aplicações econômicas, a adaptação de léxicos específicos ao domínio financeiro (Loughran & McDonald, 2011) demonstra que dicionários de sentimento de uso geral tendem a gerar classificações equivocadas quando aplicados a textos econômicos e financeiros, uma vez que diversos termos assumem significado distinto nesse contexto. Palavras associadas a risco ou volatilidade podem ser classificadas como negativas em linguagem comum, mas constituem descrições técnicas neutras em documentos financeiros. A principal conclusão do estudo é que a especificidade semântica do domínio influencia diretamente a acurácia da análise de sentimento, tornando necessária a construção de léxicos contextualizados para evitar vieses de interpretação. A formalização do sentimento por meio desses instrumentos permite transformar conceitos subjetivos em métricas quantitativas observáveis, geralmente expressas como índices, *scores* ou probabilidades. Uma vez quantificados, esses indicadores podem ser incorporados a modelos estatísticos como variáveis explicativas, variáveis dependentes ou controles, possibilitando testar hipóteses sobre relações causais ou associações entre discurso e fenômenos econômicos. (Halousková & Lyócsa, 2025) utilizaram análise de sentimento e atenção voltados a tweets, criando índices agregados que capturam o sentimento médio em séries temporais, com a finalidade de explicar o impacto do discurso na volatilidade diária de 400 ações do mercado estadunidense. Juntamente com outras métricas, obtiveram uma melhoria consistente na previsão da volatilidade em todos os setores econômicos.

Colocado o contexto teórico, o presente estudo busca definir e analisar o sentimento econômico expresso por usuários da rede social X durante o período que antecede as eleições presidenciais brasileiras de 2022. Embora Maia et al. tenha feito grandes avanços na aplicação de técnicas de análise textual para compreender fenômenos políticos, ainda é limitada a investigação sobre como discursos de natureza econômica se manifestam em ambientes digitais altamente polarizados e de que maneira esses sentimentos se associam às preferências políticas expressas pelos indivíduos. Assim, este trabalho propõe a construção de uma estratégia empírica para identificação e mensuração do sentimento econômico em tweets, combinando abordagens lexicais e métodos supervisionados de aprendizado de máquina, com o objetivo de avaliar a capacidade de capturar consistentemente padrões relevantes no debate público. Ao utilizar o sentimento econômico como variável quantitativa, o estudo busca contribuir para a compreensão das relações entre discurso econômico e comportamento político em redes sociais, oferecendo evidências empíricas sobre a utilidade de dados textuais como fonte complementar para análises em economia aplicada.

2. Materiais e Métodos

A base de dados utilizada neste estudo é composta por 270.301 tweets, previamente coletados da plataforma X (Twitter), cuja coleta foi realizada através da API da rede em Outubro de 2022, durante os debates presidenciais anteriores às eleições. Os dados estão dispostos em formato de metadados para cada tweet, contendo as variáveis “used_id”, “screen_name”, “name”, “location”, “followers_count”, “created_at”, “full_text”, “retweet_count”, “favorite_count”, “lang”, “hashtags” e “source”. Para a extração dos dados, os quais foram coletados em um arquivo de formato “jsonl”, foram criadas duas funções *parseTweetsFromFile* e *extractTweetData*, que lidam com a estrutura dos dados em jsonl, subdivididos pelos elementos “{” e “}” e pelas variáveis. Inicialmente, os textos foram padronizados quanto ao seu tipo, garantindo que todos os registros fossem tratados como cadeias de caracteres. Essa etapa visa assegurar a consistência dos dados e evitar falhas durante o processamento textual. Em seguida, os tweets foram submetidos a um processo de normalização textual utilizando o tokenizador do modelo BERTweetBR (Carneiro et al., 2025) desenvolvido especificamente para modelagem supervisionada de dados da rede social em português. O tokenizador foi carregado com a opção de normalização ativada, com o fim de realizar o tratamento automático de elementos característicos desse tipo de dado, como menções a usuários e URLs. A normalização foi realizada por meio da função *normalizeTweet*, que padroniza o texto e reduz ruídos típicos de redes sociais. Adicionalmente, os emojis presentes nos tweets foram convertidos em descrições textuais em português por meio da biblioteca *emoji*. Essa abordagem permite preservar informações semânticas e emocionais frequentemente expressas através de emojis, fornecendo uma representação textual mais rica. Após a etapa de normalização, foram removidos todos os registros com valores ausentes na variável textual processada (*clean_text*). Em seguida, foram eliminados tweets duplicados com base no conteúdo textual, mantendo-se apenas a primeira ocorrência de cada registro. Após essas etapas de limpeza, a base final passou a conter 192.954 postagens.

Então, realizou-se a segmentação entre tweets considerados economicos e não-economicos de acordo com um dicionário de palavras pertencentes ao debate economico, como “inflação”, “economia” e “educação”.¹ Isso resultou em dois dataframes diferentes, um contendo 3804 tweets considerados economicos e o outro 189150 tweets nao economicos. Para a etapa de rotulação manual, foram extraídas duas amostras aleatórias de 200 tweets cada, uma proveniente do conjunto econômico e outra do conjunto não econômico. A estratégia de amostragem adotada teve como finalidade garantir representatividade temática na base rotulada, assegurando a

¹ As palavras utilizadas foram: 'emprego', 'desemprego', 'bolsa de valores', 'mercado financeiro', 'inflação', 'renda', 'dólar', 'taxa de câmbio', 'juros', 'taxa de juros', 'indústria', 'salário', 'valor', 'auxílio', 'banco', 'crédito', 'desigualdade', 'empreendedor', 'empreendedorismo', 'finanças', 'financiamento', 'impostos', 'economia', 'igualdade', 'pib', 'produto interno bruto', 'recessão', 'crescimento', 'deflacao', 'deflação', 'superávit', 'deficit', 'déficit', 'orcamento', 'orçamento', 'orcamento publico', 'orçamento público', 'gasto público', 'dívida', 'dívida pública', 'investimento', 'investidor', 'ações', 'derivativos', 'futuros', 'b3', 'selic', 'copom', 'tesouro', 'tesouro direto', 'banco central', 'custo de vida', 'pobreza', 'renda mínima', 'salário mínimo', 'mercado de trabalho', 'carteira assinada', 'clt', 'educação'.

presença de conteúdo explicitamente econômico e conteúdo potencialmente ambíguo ou contextual. Cada tweet foi classificado segundo três categorias de sentimento econômico: positivo (1), neutro (0) e negativo (-1). Optou-se por não realizar balanceamento artificial entre as classes de sentimento, de modo a preservar a distribuição natural observada no debate. Essa escolha metodológica fundamenta-se na literatura que aponta que a alteração artificial da prevalência das classes pode distorcer estimativas probabilísticas em modelos logísticos, sobretudo quando o objetivo é realizar inferência sobre a distribuição populacional do fenômeno analisado (King & Zeng, 2001)

A distribuição das classes de sentimento apresentou a seguinte configuração: 171 tweets classificados como negativos (42,8%), 141 como positivos (35,3%) e 88 como neutros (22,0%). Observa-se que a categoria neutra representa a menor proporção da amostra, enquanto as categorias negativas e positivas apresentam maior incidência. Essa distribuição reflete a heterogeneidade do debate econômico no período analisado e reforça a decisão metodológica de preservar a prevalência natural das classes, evitando balanceamento artificial.

A base rotulada manualmente foi utilizada como conjunto de treinamento para o modelo supervisionado de classificação de sentimento. Inicialmente, cada tweet foi representado por meio de embeddings extraídos do modelo pré-treinado BERTweetBR, utilizando a representação vetorial associada ao token especial [CLS], que sintetiza semanticamente o conteúdo da sentença. Optou-se por utilizar o modelo pré-treinado como extrator de características, mantendo seus parâmetros fixos e treinando apenas o classificador linear sobre os embeddings.

Os vetores obtidos foram então utilizados como variáveis explicativas em um modelo de Regressão Logística Multinomial, estimado por máxima verossimilhança. A escolha da regressão logística deve-se à sua interpretabilidade e adequação a problemas de classificação multiclasse.

O modelo foi avaliado por meio de divisão treino-teste (80/20), resultando em 80 observações no conjunto de teste. A acurácia obtida foi de 0,51, com F1-score macro de 0,48. Observa-se desempenho superior nas classes polarizadas (negativo e positivo), com F1-scores de 0,59 e 0,62, respectivamente. Em contrapartida, a classe neutra apresentou desempenho inferior ($F1 = 0,25$), indicando maior dificuldade do modelo em distinguir conteúdos factuais ou ambíguos. Apesar das limitações, como o tamanho reduzido da amostra rotulada — que pode aumentar a variância das estimativas — e a utilização de embeddings fixos sem fine-tuning do modelo pré-treinado, o classificador apresentou desempenho superior ao baseline aleatório (33% em três classes), indicando capacidade discriminatória relevante para aplicação em larga escala. Após o treinamento, o classificador foi aplicado ao conjunto completo de 192.954 tweets. A distribuição estimada de sentimento econômico apresentou 69.544 tweets negativos (36,0%), 69.786 positivos (36,2%) e 53.624 neutros (27,8%). Observa-se que as polaridades positiva e negativa apresentam proporções praticamente equivalentes, indicando elevado grau de polarização no debate econômico durante o período analisado. Esses resultados indicam que a estratégia metodológica adotada apresenta consistência empírica suficiente para a estimação exploratória do sentimento econômico em larga escala, dentro dos limites definidos pelo desenho amostral e pela natureza dos dados analisados.

3. Cronograma

CRONOGRAMA DE ATIVIDADES												
At	SET	OUT	NOV	DEZ	JAN	FEV	MAR	ABR	MAI	JUN	JUL	AGO
1	X	X	X									
2				X	X	X	X	X	X	X		
3						X						
4							X	X	X	X		
5											X	X

4. Desempenho Acadêmico

A realização do projeto de iniciação científica foi condizente com o número de créditos escolhidos pelo aluno no 2º semestre de 2025, de forma que a carga de pesquisa necessária para a realização das etapas do projeto até aqui não resultaram em impacto negativo no aprendizado e aproveitamento das matérias do curso.

5. Bibliografia

- Carneiro, F., Vianna, D., Carvalho, J., Plastino, A., & Paes, A. (2025). BERTweet.BR: A pre-trained language model for tweets in Portuguese. *Neural Computing and Applications*, 37(6), 4363–4385. <https://doi.org/10.1007/s00521-024-10711-3>
- Halousková, M., & Lyócsa, Š. (2025). *Forecasting U.S. equity market volatility with attention and sentiment to the economy* (arXiv:2503.19767). arXiv. <https://doi.org/10.48550/arXiv.2503.19767>
- Hibbs, D. A. (1977). Political Parties and Macroeconomic Policy. *American Political Science Review*, 71(4), 1467–1487. <https://doi.org/10.2307/1961490>
- King, G., & Zeng, L. (2001). Logistic Regression in Rare Events Data. *Political Analysis*, 9(2), 137–163. <https://doi.org/10.1093/oxfordjournals.pan.a004868>
- Loughran, T., & McDonald, B. (2011). When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks. *The Journal of Finance*, 66(1), 35–65. <https://doi.org/10.1111/j.1540-6261.2010.01625.x>
- Lucas, R. E. (1972). Expectations and the neutrality of money. *Journal of Economic Theory*, 4(2), 103–124. [https://doi.org/10.1016/0022-0531\(72\)90142-1](https://doi.org/10.1016/0022-0531(72)90142-1)
- Maia, A. G., Menezes, E., & Filho, D. M. (s.d.). *How the discourse in social networks shapes election results*.
- Muth, J. F. (1961). Rational Expectations and the Theory of Price Movements. *Econometrica*, 29(3), 315. <https://doi.org/10.2307/1909635>
- Pang, B., & Lee, L. (2008). Opinion Mining and Sentiment Analysis. *Foundations and Trends® in Information Retrieval*, 2(1–2), 1–135. <https://doi.org/10.1561/15000000011>
- Simoes, H. N. Q. (s.d.). *Redes Sociais, Notícias Falsas e Privacidade de Dados na Internet*.